Napassakorn's Holding :: Project Presentation

Topic: Text Summarization

Content

- Dataset
  - Example (Text & Summary)
- Evaluation
- Baseline
- Relevant works or models
- Preprocessing
  - for Baseline
  - for Our model
- Proposed model
- Finetune
- Result

Dataset

Thairath222k 200,000+ records

https://github.com/nakhunchumpolsathien/TR-TPBS

Train 0.6

Eval 0.2

Test 0.2

Download TR-TPBS Dataset

File	Remark	Size
TR-TPBS	contains `title`, `body`, `summary`, `labels`, `tags` and `url` columns.	2.05 GB

Additional Datasets

These two files are the previous versions of TR-TPBS, before being combined. Be noted that the articles in these f
are preprocessed with slightly different filtering-out conditions of that TR-TPBS. The number in the end of datase
name indicates the approximate number of articles contained in each dataset. The newest articles contained in th
two files are published online up to December 2019.

File	Remark	Size
Thairath-222k	contains `title`, `body`, `summary`, `labels`, `tags`, `url` and `date` columns.	1.72 GB
ThaiPBS-111k	contains similar columns as Thairath-222k's except `date`.	0.51 GB

Dataset: Example

Text:

“กรุงเทพ ฟุตซอลนักเรียน คัพ ครั้งที่ 14,วันที่ 1 ธ.ค.62 การแข่งขันฟุตซอล เอสแบค-นอร์ทกรุงเทพ ฟุตซอลนักเรียน คัพ ครั้งที่ 14 รอบชิงชนะเลิศรุ่นอายุไม่เกิน 18 ปี ร.ร.สุขุมนวพันธ์อุปถัมภ์ ออกนำก่อนจาก ปราโมทย์ สมบูรณ์ผล จากนั้น ธีรวุฒิ ศรีชารู ตีเสมอให้ ร.ร.สุรศักดิ์มนตรี หมดเวลาเสมอกัน 1-1 ยิงจุดโทษตัดสิน ร.ร.สุรศักดิ์มนตรี ชนะด้วยสกอร์รวม 5-4 ส่วนในคู่ชิงอันดับที่ 3 ร.ร.ปทุมคงคา ชนะ ร.ร.วัดเบญจมบพิตร 3-0 นักเตะยอดเยี่ยมตกเป็นของ ภูมินทร์ นกแก้ว นักเตะจาก ร.ร.สุรศักดิ์มนตรี,ผลการแข่งขันคู่อื่นๆ รุ่นอายุไม่เกิน 13 ปี ชิงชนะเลิศ อิสลามวิทยาลัยแห่งประเทศไทย ชนะ ร.ร.ปทุมคงคา 1-0 ชิงอันดับที่ 3 ร.ร.สุขมนวพันธ์อุปถัมภ์ ชนะ ร.ร.ปทุมคงคา สมุทรปราการ 3-1 รุ่นอายุไม่เกิน 15 ปี ชิงชนะเลิศ ร.ร.พรตพิทยพยัต ชนะ ปทุมคงคา สมุทรปราการ 3-1 ชิงอันดับที่ 3 อิสลามวิทยาลัยแห่งประเทศไทย ชนะ ร.ร.ราชวินิตบางเขน 4-3,ในพิธีปิดการแข่งขันและมอบรางวัล ผู้ช่วยศาสตราจารย์ ดร.ประเสริฐ ประวัติรุ่งเรือง อธิการบดี ม.นอร์ทกรุงเทพ เป็นประธานในพิธีปิด พร้อมด้วยคณะผู้บริหาร ม.นอร์ทกรุงเทพ ได้แก่ ผศ.ดร.ปัทมา รูปสุวรรณกุล,”

Summary:

“ร.ร.สุรศักดิ์มนตรีชนะจุดโทษคว้าแชมป์รุ่นอายุไม่เกิน 18 ปี ด้าน ร.ร.พรตพิทยพยัตคว้าแชมป์รุ่นอายุไม่เกิน 15 ปี และอิสลามวิทยาลัยแห่งประเทศไทย แชมป์รุ่นอายุไม่เกิน 13 ปี โต๊ะเล็ก เอสแบค-นอร์ท”

Evaluation

ROUGE-1 & ROGUE-2

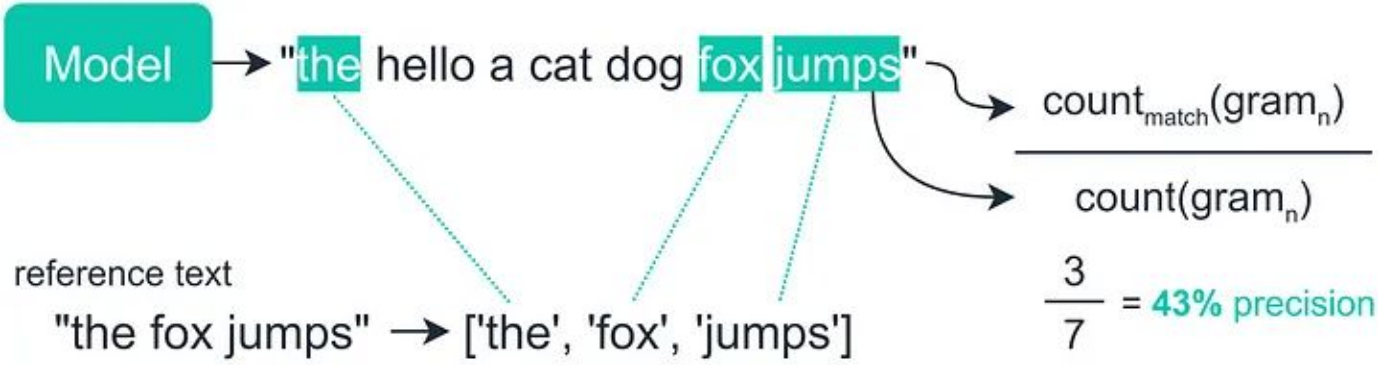

https://towardsdatascience.com/the-ultimate-performance-metric-in-nlp-111df6c64460

Evaluation

ROUGE-L measures the longest common subsequence (LCS) between our model output and reference.

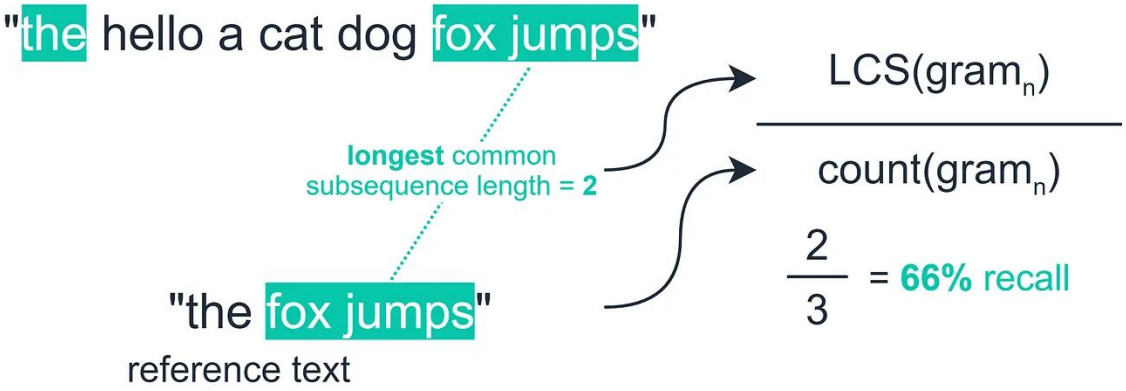

https://towardsdatascience.com/the-ultimate-performance-metric-in-nlp-111df6c64460

Baseline

LEAD-3

LEAD-200

Lead 200 characters

Sentence-Level Extractive Text Summarization

Nathan Zhao, Yijun Jiang, Yi Liu
{nzz2102, yijunj, yiliu021}@stanford.edu

2 Related Work

NeuSum is the first end-to-end neural architecture of its kind. Nevertheless, there have been several algorithmic approaches to extractive summarization. The simplest is the LEAD-3 benchmark, which proposes the first three sentences of the document as the summary. It is the best extractive baselines (as of Jan. 2018) for the Newsroom dataset with an average Rouge-1 F1 score of 30% [3]. TextRank [4] is an unsupervised learning algorithm which extracts keyphrases. Its benchmark score on Newsroom is 20% and represents the best non-brute force or LEAD-3 type benchmark on the Newsroom dataset. Other types of extractive summarization include graph based approaches [5], bayesian topic models [6], etc.

The NeuSum architecture has not been benchmarked on this dataset but has consistently achieved much higher Rouge scores when applied to the CNN/Daily mail dataset against other state of the

Final report of Stanford CS224N (Natural Language Processing) final project in Winter 2019.

Relevant works or models

(1) https://github.com/nakhunchumpolsathien/ThaiSum
(2) https://docs.adapterhub.ml/model_overview.html
(3) https://docs.adapterhub.ml/contributing/adding_adapters_to_a_model.html
(4) https://huggingface.co/docs/transformers/model_doc/mt5
(5) https://huggingface.co/docs/transformers/model_doc/flan-t5
(6) https://huggingface.co/thanathorn/mt5-cpe-kmutt-thai-sentence-sum

Relevant works or models (1)

(1) https://github.com/nakhunchumpolsathien/ThaiSum

0.2 Trained Models

0.2.1 BertSum

Model	Size
BertSumExt	2.1 GB
BertSumAbs	3.6 GB
BertSumExtAbs	3.6 GB

0.2.2 ARedSum

Model	Size
ARedSumBase	2.1 GB
ARedSumCTX	737.6 MB
ARedSumSEQ	2.3 GB

Relevant works or models (1)

ThaiSum

A dataset for Thai text summarization.

Notes

- ThaiSum คือชุดข้อมูลสำหรับเทรนระบบสรุปข้อความภาษาไทย จากเว็บไซต์ ไทยรัฐ, ไทยพีบีเอส, ประชาไท และ เดอะแสตนดาร์ด
- ผู้สนใจยังสามารถดาวน์โหลด โมเดลที่เทรนแล้วไปทดสอบกับ test set ของท่าน โดยเราได้ modify ซอร์ซโค้ดของ BertSum และ ARedSum ให้รองรับภาษาไทย ศึกษาเพิ่มเติมได้ที่ ARedSum_for_Thai_text.ipynb และ BertSum_for_Thai_text.ipynb ทั้งนี้ท่านต้อง process ข้อความของท่านเองให้เหมาะกับแต่ละโมเมลโดยเรามีตัวอย่างไว้ให้แล้ว
- เราระบุที่มาของทุกข่าวในชุดข้อมูลนี้ในคอลัมน์ url หากท่านต้องการดัดแปลงและเผยแพร่ชุดข้อมูลนี้ต่อ กรุณาใส่ที่มาของทุกๆบทความด้วย
- ชุดข้อมูลนี้ยังเป็นประโยชน์ต่อระบบประมวลผลทางภาษาไทยอื่นๆเช่น news classification (ทั้งแบบ multi-label และ single-label), headline generation, language modelling

Relevant works or models (1)

4.1 Experimental Settings

To train sequence-to-sequence based models, we split the dataset into 336,868/11,000/11,000 documents for training, validation and testing. Input documents were truncated at 500 words. We used 'bert-base-multilingual-uncased' for fine-tuning. We trained BertSum and ARedSum models on two GPUs (NVIDIA Titan RTX). Other parameters were set similar to the oiginal experiments of the corresponding papers. The summaries produced by extractive models, except ORACLE, were limited to 2 sentences.

0.1 Dataset

Dataset	Remark
thaisum.csv	contains `title`, `body`, `summary`, `type`, `tags`, `url` columns. (2.9 GB)
test_set.csv	contain `title`, `body`, `summary`, `type`, `tags`, `url` columns. (113 MB)
validation_set.csv	contain `title`, `body`, `summary`, `type`, `tags`, `url` columns. (113 MB)

Relevant works or models (2-3)

(2) https://docs.adapterhub.ml/model_overview.html

(3) https://docs.adapterhub.ml/contributing/adding_adapters_to_a_model.html

Relevant works or models (2-3)

Recap Adapters

Adapter is a small and task-specific module that allow a pre-trained language model to be adapted to a new task or domain with minimal additional training. They attach to the pre-trained model and are trained separately, making it easier and more efficient to adapt the model to new tasks. Adapters require less additional data and compute resources than full fine-tuning, and enable better model interpretability.

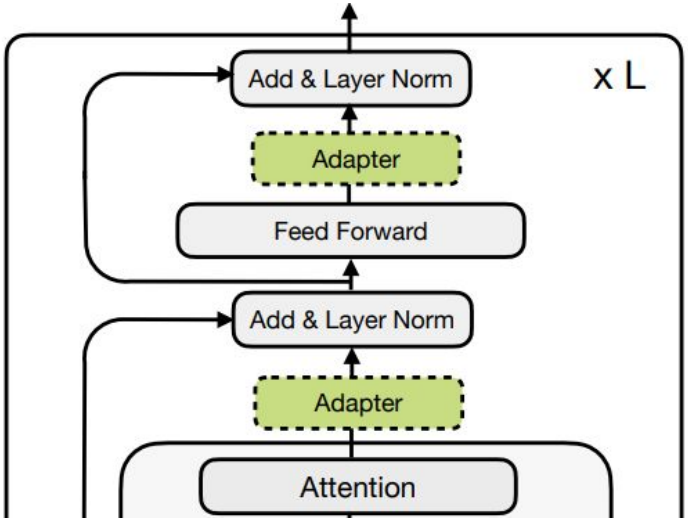

$$\boldsymbol{h} \leftarrow \boldsymbol{h} + f(\boldsymbol{h}\boldsymbol{W}_{\text{down}})\boldsymbol{W}_{\text{up}}.$$

Relevant works or models (2-3)

Method	number of parameters
Prompt Tuning	$l \times d$
Prefix Tuning (attn)	$2ld \times 3 \times 12$
Adapter variants (attn)	$2rd \times 3 \times 12$
Adapter variants (ffn)	$2rd \times 2 \times 12$
LoRA (attn)	$4rd \times 3 \times 12$
LoRA (ffn)	$10rd \times 2 \times 12$
MAM Adapter (our proposed model)	$2ld \times 3 \times 12 + 2rd \times 2 \times 12$

+ Prefix Tuning

+ LoRA

Relevant works or models (4-5)

(4) https://huggingface.co/docs/transformers/model_doc/mt5
(5) https://huggingface.co/thanathorn/mt5-cpe-kmutt-thai-sentence-sum

The architecture of the model is based on **mT5** model
and fine-tuned on text-summarization pairs in Thai language.

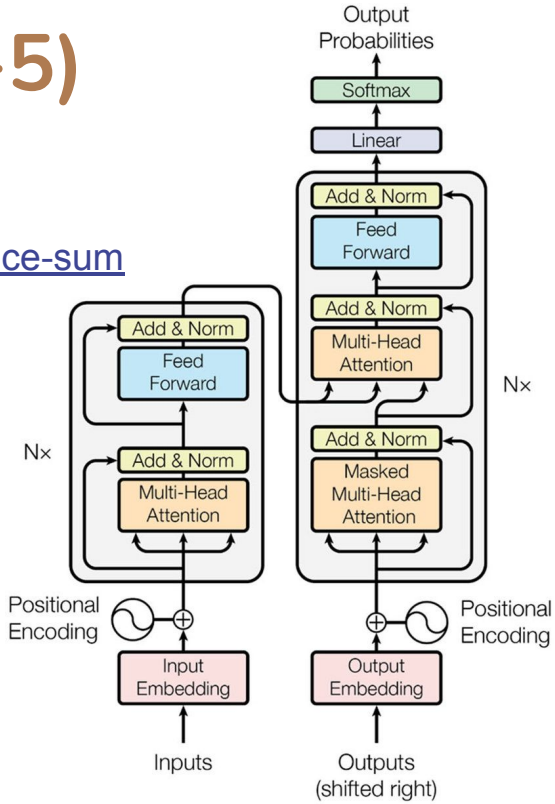

Preprocessing (for baseline)

1. Extract first 200 characters from news' body (LEAD-200)

2. Tokenize with **attacut** (using 40 mins with 44,100 sentence)
   - We have tried **deepcut** , but it took a very very long time.

Preprocessing (for our model)

1. Extract first 500 characters, representing the whole body, from news' body

2. Tokenize the extracted body and summary (labels) with T5Tokenizer
   pretrained_weight from ***thanathorn/mt5-cpe-kmutt-thai-sentence-sum***

Proposed model

- **Base model:** T5ForConditionalGeneration
- **Tokenizer:** T5Tokenizer
- **Pretrained Weights:** Hugging Face 🤗 `thanathorn/mt5-cpe-kmutt-thai-sentence-sum`

To build our model:

1. Import Pretrained Weights into T5Tokenizer and T5ForConditionalGeneration model
2. Extend an adapter which is `mam_adapter` (adapter-transformers)

Finetune

GPU: A100
3 hr 49min

```python
import evaluate
rouge = evaluate.load("rouge")
```

```python
import numpy as np
def compute_metrics(eval_pred):
    predictions, labels = eval_pred
    decoded_preds = tokenizer.batch_decode(predictions, skip_special_tokens=True)
    labels = np.where(labels != -100, labels, tokenizer.pad_token_id)
    decoded_labels = tokenizer.batch_decode(labels, skip_special_tokens=True)

    result = rouge.compute(predictions=decoded_preds, references=decoded_labels, use_stemmer=True)

    prediction_lens = [np.count_nonzero(pred != tokenizer.pad_token_id) for pred in predictions]
    result["gen_len"] = np.mean(prediction_lens)

    return {k: round(v, 4) for k, v in result.items()}
```

```python
from transformers.adapters import MAMConfig
config = MAMConfig()
model.add_adapter("mam_adapter", config=config)

model.train_adapter("mam_adapter")

from transformers import TrainingArguments, AdapterTrainer
from transformers import DataCollatorForSeq2Seq
data_collator = DataCollatorForSeq2Seq(tokenizer=tokenizer,model='thanathorn/mt5-cpe-kmutt-thai-sentence-sum')
training_args = TrainingArguments(
    output_dir = './mam-mt5',        # output directory
    num_train_epochs=3,              # total # of training epochs
    per_device_train_batch_size=16,  # batch size per device during training
    per_device_eval_batch_size=16,   # batch size for evaluation
    warmup_steps=500,                # number of warmup steps for learning rate scheduler
    weight_decay=0.01,               # strength of weight decay
                                     # directory for storing logs
)
trainer = AdapterTrainer(
    model=model,
    args=training_args,
    train_dataset=train_dataset,
    eval_dataset = eval_dataset,
    data_collator=data_collator,
    compute_metrics=compute_metrics,

)
```

Result

	rouge1	rouge2	rougeL	rougeLsum
Baseline	**0.316015**	**0.196549**	0.264958	0.265026
Our work	0.310302	0.188531	**0.271182**	**0.271239**

Result

```
'rouge1': [0.0],
'rouge2': [0.0],
'rougeL': [0.0],
'rougeLsum': [0.0]
```

Example Result

Body lead-200
เมื่อเวลา 11.00 น. วันที่ 11 ม.ค. นายชูชาติ กีฬาแปง ผวจ.พิษณุโลก ตรวจติดตามปัญหาภัยแล้งที่ อ.บางระกำ โดยจุดแรกที่สะพานบางแก้ว พบแม่น้ำลำคลองเริ่มแห้ง บางจุดแห้งขอด โดยคลองบางแก้วจะรับน้ำมาจากหาด

Summary Label
เมื่อเวลา 11.00 น. วันที่ 11 ม.ค. นายชูชาติ กีฬาแปง ผวจ.พิษณุโลก ตรวจติดตามปัญหาภัยแล้งที่ อ.บางระกำ โดยจุดแรกที่สะพานบางแก้ว พบแม่น้ำลำคลองเริ่มแห้ง บางจุดแห้งขอด

Predicted from model
น้าป่าไหลทะลัก น้าป่าไหลทะลัก น้าป่าไหลทะลัก น้าป่าไหลเข้าคลองบางแก้ว

Result

```
'rouge1': [0.434782],
'rouge2': [0.272727],
'rougeL': [0.434782],
'rougeLsum': [0.434782]
```

Example Result

Body lead-200
เมื่อเวลา 16.00 น. วันที่ 29 พ.ย. บริเวณที่ทำการข้อมูลข่าวสารนักท่องเที่ยวบ้านผาวาย ต.ปวนพุ อ.หนองหิน จ.เลย นายวิโรจน์ จิวะรังสรรค์ ผู้ว่าราชการจังหวัด นำนักท่องเที่ยวจำนวนมาก ทยอยเดินทางไปสัมผัสบรรยากาศ

Summary Label
นักท่องเที่ยวแห่ชมทิวทัศน์มุม 360 องศา ภูป่าเปาะ ฟูจิเมืองเลย สัมผัสบรรยากาศทางธรรมชาติและวิถีชาวบ้าน

Predicted from model
นักท่องเที่ยวแห่ชมวิวทิวทัศน์ มุม ขุนเขา แมกไม้รอบด้าน 360 องศา นักท่องเที่ยวแห่ชมวิว ภูหอ หรือที่รู้จักกันในนาม ฟูจิเมืองเลย

Result

```
'rouge1': [0.140845],
'rouge2': [0.028986],
'rougeL': [0.084507],
'rougeLsum': [0.084507]
```

Example Result

Body lead-200

เมื่อวันที่ 12 ม.ค.59 ที่ทำเนียบรัฐบาล พล.อ.ประวิตร วงษ์สุวรรณ รองนายกรัฐมนตรีและรมว.กลาโหม กล่าวภายหลังการประชุมคณะรัฐมนตรี (ครม.) ว่า ที่ประชุมครม.อนุมัติให้รับซื้อยางพาราโดยตรงจากเกษตรกร

Summary Label

บิ๊กป้อม เตรียมส่ง คสช.ลงพื้นที่ช่วยรับซื้อยาง ปัดตัวแกนนำปรับทัศนคติ ชี้ยังไม่คิดฟื้นขุดคอคอดกระ รอรัฐบาล ลต.ดำเนินการ แจง ครม.แก้ประมงคืบหน้า เมินข้อเสนอ มารา ปาตานี โอไอซี คนกลางถกสันติสุข อ้างเป็นเรื่องภายใน

Predicted from model

บิ๊กตู่ ยัน ครม.อนุมัติให้รับซื้อยางพารา ยัน คสช. แก้ปัญหาราคาซื้อยางพารา ยัน คสช. เร่งแก้ปัญหา